Cátedra: Fintech con IA · **Docente:** José Leonardo González · **Sesión 2:** Diseño transaccional y prototipo · **Entregable:** Baseline de IA (dataset sintético documentado + modelo + métricas)
Equipo D: Jesus Sayago, Daniel Haro, Ronald Gomez, David Crespo · **Repositorio:** github.com/PepeTza/InvierteYa · Carpetas `ia/`, `data/`, `docs/ia/`

Ficha del modelo baseline · Perfil de riesgo y tutor didáctico

InvierteYa · Equipo D · Sesión 2 · Línea D (perfil de riesgo y recomendación de portafolio)
Código: `ia/` · Métricas completas: `docs/ia/metricas.json` · Dataset: `docs/ia/DATASET.md`

> **Componente SIMULADO / baseline:** entrenado solo con datos sintéticos. Sirve para demostrar el flujo y medir contra las metas de la ficha de IA de la Sesión 1. No está listo para recomendar a personas reales.

1. Qué hace

Cuando el usuario termina el cuestionario de 10 preguntas, la IA tiene dos partes:

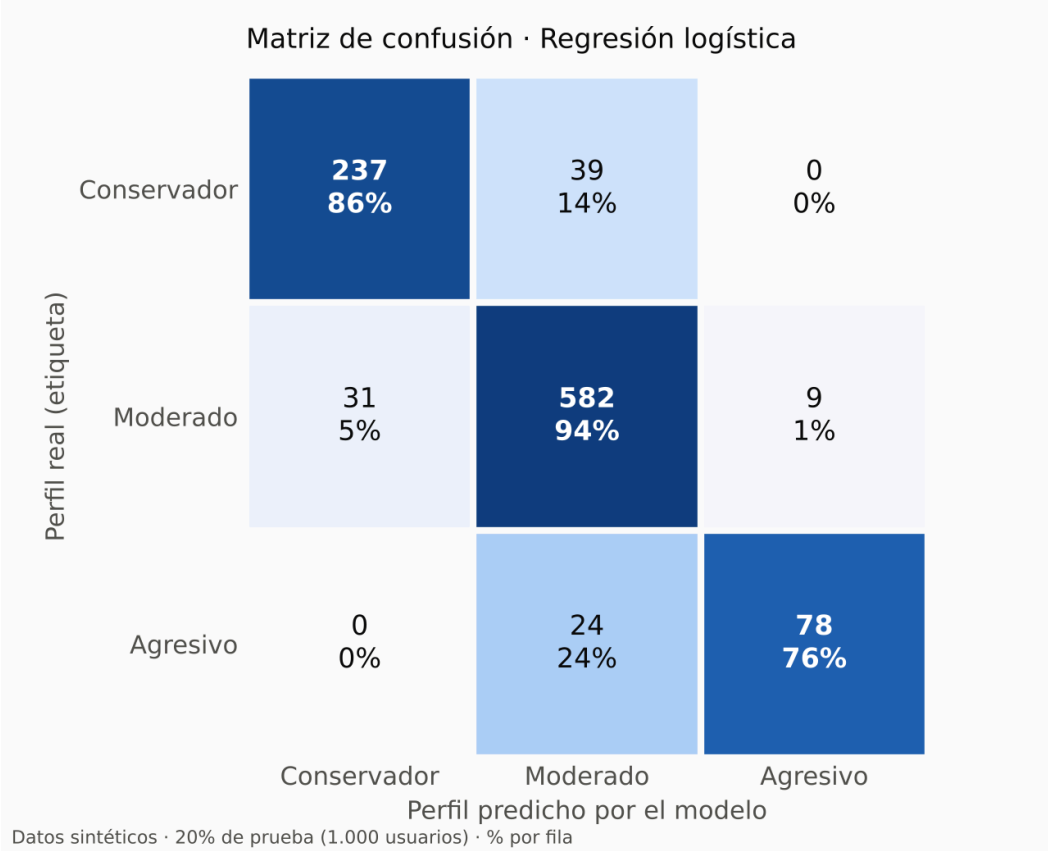
1. **Clasificador de perfil de riesgo** (este modelo). Devuelve Conservador, Moderado o Agresivo, la probabilidad de cada perfil y una explicación en lenguaje simple. El perfil define el portafolio del fideicomiso en el que se asignan las unidades.
2. **Tutor didáctico con contenido predefinido** (sin LLM). Selecciona la microlección adecuada según el perfil, el nivel de conocimiento y el paso del flujo (sección 8).

2. Resultado frente a las metas de la Sesión 1

Evaluación sobre el 20% de prueba (1.000 usuarios que el modelo no vio), con las reglas de seguridad aplicadas:

Meta (ficha de IA, Sesión 1)	Resultado	¿Cumple?
Exactitud ≥ 85%	**89,7%**	✅
F1 por clase ≥ 0,80	Conservador **0,87** · Moderado **0,92** · Agresivo **0,83**	✅
0 Conservadores clasificados como Agresivos	**0**	✅
Sin fondo de emergencia nunca Agresivo	0 casos (la regla se aplica después del modelo)	✅
Probabilidad < 60% → revisión humana	Marca el **5,2%** de los casos	✅

Métricas adicionales (anticipo de la Sesión 3): **AUC macro (uno contra todos) = 0,978**. Precisión por clase: 0,88 · 0,90 · 0,90. Recall por clase: 0,86 · 0,94 · 0,76.



Lectura de la matriz. Los errores solo ocurren entre perfiles **vecinos**: nunca se confunde Conservador con Agresivo ni al revés. El error más frecuente es clasificar a un Agresivo como Moderado (24 casos), que es el error **seguro**, porque recomienda menos riesgo del que la persona tolera. Solo 9 Moderados (1%) se clasificaron como Agresivos.

3. Modelos comparados

Ambos son modelos explicables, como se definió en la Sesión 1. Los hiperparámetros se eligieron con validación cruzada estratificada de 5 pliegues sobre el 80% de entrenamiento (métrica: F1 macro).

Modelo	Hiperparámetros elegidos	F1 macro (val. cruzada)	Exactitud (prueba)	F1 Agresivo	Conserv.→Agresivo	¿Cumple todo?
Árbol de decisión	profundidad 8, hoja mín. 5	0,837	85,9%	0,76	0	❌ (F1 Agresivo)
Regresión logística multinomial	C = 1, sin balanceo de clases	**0,886**	**89,7%**	**0,83**	**0**	✅ **elegido**

Por qué gana la regresión logística. La regla de idoneidad suma puntos de varias respuestas, y una regresión logística también combina las respuestas de forma aditiva, así que la aproxima mejor. Un árbol necesita muchos cortes para imitar una suma.

Decisión sobre el balanceo de clases. Con `class_weight="balanced"` el modelo clasificaba a 39 Moderados como Agresivos (recomendaba de más), y el F1 de Agresivo quedaba por debajo de 0,80 en 4 de 6 semillas. Sin balanceo, esos casos bajan a 9. Se eligió la opción que se equivoca hacia el lado conservador.

4. Estabilidad

Se repitió todo el proceso (dataset nuevo + entrenamiento + evaluación) con 5 semillas distintas:

Semilla	1	7	99	123	2024
Exactitud	90,8%	92,0%	89,8%	90,2%	91,0%
F1 mínimo por clase	0,857	0,854	0,802	0,800	0,833
Conservador→Agresivo	0	0	0	0	0

La exactitud promedio es de 90,8% y nunca aparece el error grave. **Límite honesto:** el F1 de la clase Agresivo queda justo en el borde de la meta (peor caso 0,800). Es la clase minoritaria y la primera que hay que vigilar.

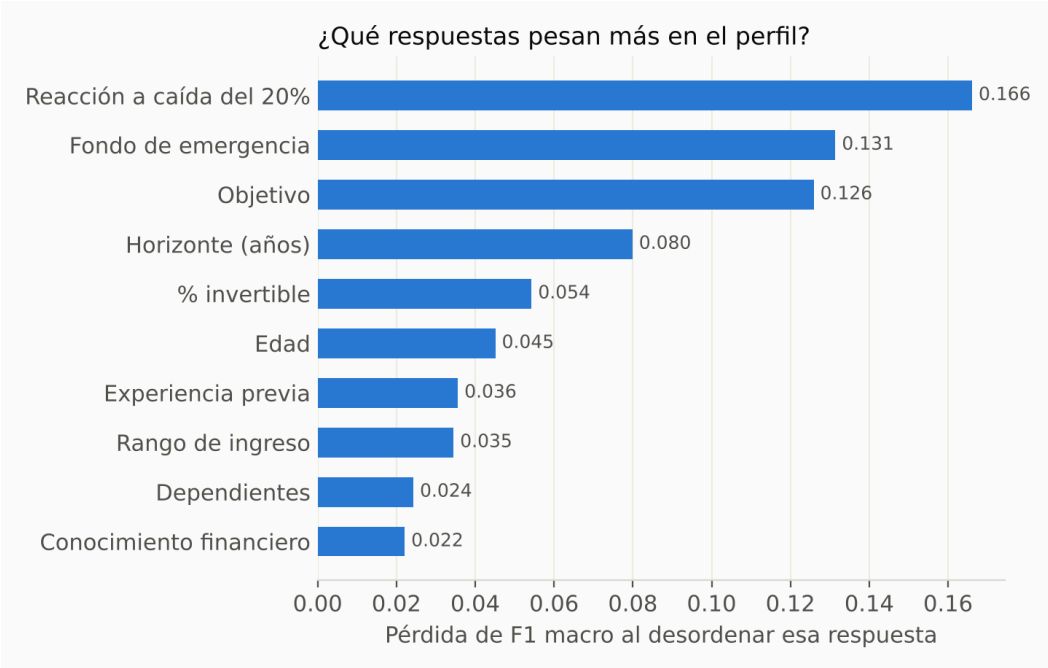
5. Sesgo: métricas por grupo

Mitigación comprometida en la Sesión 1: revisar que el modelo no trate distinto a un grupo (por ejemplo, "siempre clasificar a los jóvenes como agresivos").

Grupo	n	Exactitud	F1 macro	% Agresivo real	% Agresivo predicho
Edad 18-24	277	89,9%	0,89	13,4%	12,3%
Edad 25-40	525	88,9%	0,85	9,5%	7,4%
Edad 41+	198	91,4%	0,89	7,6%	7,1%
Ingreso bajo (1-2)	539	89,4%	0,83	3,5%	3,0%
Ingreso medio (3)	234	89,7%	0,86	12,8%	9,8%
Ingreso alto (4-5)	227	90,3%	0,89	23,4%	21,2%

La exactitud es pareja entre grupos (88,9% a 91,4%), y en ningún grupo el modelo predice **más** Agresivos de los que hay en realidad: no exagera el riesgo de los jóvenes. El F1 más bajo está en el ingreso bajo (0,83), porque ahí casi no hay Agresivos. Es un punto a vigilar con datos reales.

6. Explicabilidad



Importancia por permutación: se desordena una respuesta a la vez y se mide cuánto empeora el F1. Las respuestas que más pesan son la **reacción ante una caída del 20%**, el **fondo de emergencia** y el **objetivo**. Las tres son preguntas de actitud ante el riesgo, que es lo que se busca medir. La edad y el ingreso pesan poco.

Además, cada respuesta de la API incluye una **explicación en lenguaje simple** (por ejemplo: "Te asignamos el perfil Conservador sobre todo porque prefieres proteger tu dinero y venderías ante una caída del 20%").

7. Reglas de seguridad y supervisión humana

El orden de decisión está implementado en `ia/predictor.py` y `app/core/servicio.py`:

1. El modelo estima la probabilidad de cada perfil.
2. **Regla no negociable:** sin fondo de emergencia nunca Agresivo (pasa a Moderado).
3. **Probabilidad < 60% → revisión humana:** el caso entra a la cola de un asesor (`revisiones_perfil`). Mientras tanto se asigna **provisionalmente el perfil más conservador** entre el modelo y las reglas, y el usuario ve un aviso.
4. **Respaldo:** si el modelo no se puede cargar, la API usa las reglas de `app/core/perfil.py` y lo indica en el campo `motor`. La demo nunca se cae por el modelo.

Integración en la API

`POST /v1/usuarios/{id}/perfil` devuelve, además de lo que ya devolvía, estos campos nuevos: `probabilidad`, `probabilidades` (los 3 perfiles), `revision_humana`, `perfil_reglas` (para comparar) y `motor` (qué decidió: el modelo o las reglas). Están documentados en `docs/openapi.yaml`.

Casos de prueba (`tests/test_ia.py`)

Caso	Qué verifica
CP-16	El modelo cumple las 3 metas en el 20% de prueba
CP-17	Con el modelo conectado, sin fondo de emergencia nunca sale Agresivo
CP-18	Probabilidad < 60% → revisión humana y perfil provisional más conservador
CP-19	Sin modelo disponible, la API sigue funcionando con las reglas
CP-20	El dataset es reproducible y solo tiene columnas sintéticas (sin datos personales)
CP-21	La exactitud de cada grupo de edad es ≥ 80%

8. Tutor didáctico (contenido predefinido)

Decisión del equipo: no se usa un LLM. El contenido lo escribe y revisa una persona, así que no hay alucinaciones ni promesas de rendimiento. La parte "inteligente" es la **regla de selección** (`app/core/tutor.py`):

1. Solo lecciones del **paso del flujo** en el que está el usuario.
2. Primero las del **perfil exacto** del usuario y luego las marcadas "Todos".
3. Primero las de su **nivel** (conocimiento 1-2 → básico; 3-5 → intermedio).
4. **Nunca repite** una lección que el usuario ya vio.
5. **No aparece cuando se rechaza un pago:** InvierteYa no conoce la causa real; solo se muestra un mensaje según el código de respuesta.

Momentos del flujo en que aparece: fin del cuestionario, firma de la adhesión (antes del primer aporte), asignación de unidades, consulta del portafolio y antes de un rescate.

Catálogo de lecciones (tabla `id`, `paso_del_flujo`, `perfil`, `nivel`, `texto`):

id	Paso del flujo	Perfil	Nivel	Título	Texto
L01	`CUESTIONARIO_COMPLETO`	Conservador	básico	¿Qué significa ser Conservador?	Prefieres no perder dinero aunque eso signifique ganar menos. Por eso tu portafolio tiene sobre todo renta fija: instrumentos que pagan intereses conocidos de antemano.
L02	`CUESTIONARIO_COMPLETO`	Moderado	básico	¿Qué significa ser Moderado?	Aceptas algunos altibajos a cambio de que tu dinero crezca más. Tu portafolio combina renta fija, fondos y acciones en partes parecidas.
L03	`CUESTIONARIO_COMPLETO`	Agresivo	básico	¿Qué significa ser Agresivo?	Buscas el mayor crecimiento posible y toleras caídas temporales. Tu portafolio tiene más acciones, que pueden subir mucho pero también bajar.
L04	`ANTES_PRIMER_APORTE`	Todos	básico	¿Dónde queda mi dinero?	Tu dinero no queda en InvierteYa: entra a un fideicomiso administrado por un banco regulado. Ese patrimonio está separado del banco y de nosotros.
L05	`UNIDADES_ASIGNADAS`	Todos	básico	¿Qué es una unidad de participación?	Es tu parte del fideicomiso. Si aportaste $20 y cada unidad vale $1,25, recibiste 16 unidades. Si las inversiones suben, el valor de cada unidad sube y tu saldo también.
L06	`UNIDADES_ASIGNADAS`	Todos	intermedio	¿Por qué compramos por lotes?	Juntamos los aportes de muchas personas y el fideicomiso compra títulos completos una vez al día. Así una inversión de $5 accede a instrumentos que normalmente piden mucho más.
L07	`VER_PORTAFOLIO`	Conservador	básico	¿Qué es la renta fija?	Es prestarle dinero a una empresa o al Estado a cambio de intereses. Es la parte más estable de tu portafolio, aunque no está libre de riesgo.
L08	`VER_PORTAFOLIO`	Todos	básico	¿Por qué sube y baja mi saldo?	El valor de tu unidad cambia con el precio de los títulos del fideicomiso. Una baja de un día es normal; lo importante es tu horizonte de inversión.
L09	`VER_PORTAFOLIO`	Agresivo	intermedio	Diversificar no es opcional	Aunque tu perfil acepte más riesgo, repartir el dinero entre varios instrumentos reduce el golpe si a uno le va mal.
L10	`ANTES_RESCATE`	Todos	básico	Antes de retirar	Retirar se llama rescatar unidades: se venden al valor del día. Si el mercado está bajo, podrías recibir menos de lo que aportaste.

9. Limitaciones

- **Datos sintéticos:** el modelo aprende a imitar la regla de idoneidad del equipo (con ruido). Una exactitud alta no prueba que la recomendación sea adecuada para personas reales. Antes de producción hay que validar la regla con un asesor certificado y reentrenar con datos reales anonimizados.
- **El cero Conservador→Agresivo** se da en parte porque en los datos sintéticos esos perfiles están lejos (≥ 6 puntos de diferencia). Con datos reales debe seguir siendo una prueba bloqueante.
- **La clase Agresivo es frágil** (10% de los datos, F1 de 0,80 a 0,86 según la semilla).
- **No detecta respuestas incoherentes o apresuradas** (riesgo 3 de la ficha). Las preguntas de control quedan para la Sesión 3.
- **Versión de scikit-learn:** el modelo se guardó con la versión indicada en `metricas.json`. Si el equipo usa otra, basta con correr `python ia/entrenar.py` para regenerarlo.

10. Cómo reproducirlo

```
python ia/generar_dataset.py   # data/dataset_sintetico.csv
python ia/entrenar.py          # modelo + metricas.json + gráficos (unos 20 s)
python -m pytest -v            # 21 casos: CP-01 a CP-21
```

11. Fuentes

- Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830. Biblioteca usada para los modelos y las métricas.
- scikit-learn 1.9.1. *3.4. Metrics and scoring: quantifying the quality of predictions*. Definición de F1 por clase y F1 macro, y convención de la matriz de confusión (filas = clase real, columnas = clase predicha). https://scikit-learn.org/stable/modules/model_evaluation (consultado el 8-nov-2026).
- scikit-learn 1.9.1. *sklearn.inspection.permutation_importance*. La importancia es la caída del puntaje al desordenar una columna. https://scikit-learn.org/stable/modules/generated/sklearn.inspection.permutation_importance.html (consultado el 8-nov-2026).
- Equipo D (2026). *S1_EquipoD_Concepto*, sección 7: ficha del componente de IA (metas, riesgos y mitigaciones).

Ficha del dataset sintético · Perfil de riesgo

InvierteYa · Equipo D · Sesión 2 — Archivo: `data/dataset_sintetico.csv` · Generador: `ia/generar_dataset.py`

> **100% sintético.** Ninguna fila corresponde a una persona real. No hay nombres, cédulas, correos, teléfonos ni datos de tarjetas. Cumple la regla de la cátedra: solo datos sintéticos.

1. Para qué sirve

Entrenar y evaluar el **modelo baseline** que clasifica a un usuario como **Conservador, Moderado o Agresivo** a partir de las 10 respuestas del cuestionario definido en la ficha del componente de IA (Sesión 1). Como InvierteYa todavía no tiene usuarios, no existen datos reales: se simulan.

2. Resumen

Dato	Valor
Filas	5.000 usuarios ficticios (`syn_00001` a `syn_05000`)
Columnas	`id` + 10 variables del cuestionario + 3 columnas de trazabilidad + `perfil` (etiqueta)
Semilla	42 (el archivo se regenera idéntico con `python ia/generar_dataset.py`)
Etiquetas	Conservador 1.382 (27,6%) · Moderado 3.109 (62,2%) · Agresivo 509 (10,2%)
División	80% entrenamiento (4.000) / 20% prueba (1.000), estratificada

3. Variables

#	Variable	Tipo	Valores	Distribución simulada
1	`edad`	entero	18 a 65	70% entre 20 y 40 años (segmento principal de la Sesión 1); media 33
2	`ingreso_rango`	ordinal	1 (más bajo) a 5	25% · 30% · 24% · 13% · 8%
3	`pct_invertible`	entero	1% a 50% del ingreso	mediana 13%; sube con el ingreso
4	`horizonte_anios`	numérico	0,5 · 1 · 2 · 3 · 5 · 7 · 10	más largo en menores de 35
5	`objetivo`	categórica	proteger · crecer · ganar_rapido	33% · 46% · 21%
6	`reaccion_caida_20`	categórica	vender_todo · esperar · comprar_mas	32% · 40% · 28%
7	`experiencia_previa`	sí/no		21% sí
8	`fondo_emergencia`	sí/no		55% sí; más probable con mayor ingreso
9	`dependientes`	entero	0 a 5	51% sin dependientes; más con la edad
10	`conocimiento`	ordinal	1 a 5 (autoevaluado)	68% en niveles 1-2 (público que nunca invirtió)

Coherencia entre respuestas. Se usa un rasgo latente de *tolerancia al riesgo* (normal estándar, **no se guarda en el CSV**) que influye en el objetivo, la reacción ante caídas, el horizonte, la experiencia y el % invertible. Así, quien quiere "ganar rápido" tiende a no vender ante una caída, como pasa en un

cuestionario real. Sin este rasgo, casi todos los usuarios quedaban como Moderados (solo 5% Agresivos) y el modelo no tenía ejemplos suficientes de esa clase.

Columnas de trazabilidad (no las ve el modelo): `puntaje_reglas` (0 a 19), `ruido` y `puntaje_con_ruido`. Permiten auditar por qué cada fila tiene su etiqueta.

4. Cómo se asigna la etiqueta

1. **Puntaje de idoneidad** con la misma regla del prototipo (`app/core/perfil.py`, máximo 19 puntos): horizonte (0-3), objetivo (0-3), reacción ante una caída del 20% (0-3), % invertible (0-2), edad (0-2), experiencia (0-1), conocimiento (0-2), sin dependientes (0-1) e ingreso (0-2).
2. **Ruido gaussiano** (desviación de 0,75 puntos). Representa que dos asesores no siempre coinciden con un cliente que está cerca del límite entre dos perfiles. Por el ruido, el **7,2%** de las etiquetas cambia respecto de la regla pura. Por eso **ningún modelo puede llegar al 100%**: el techo práctico ronda el 93%.
3. **Cortes:** menos de 7 puntos → Conservador; de 7 a menos de 13 → Moderado; 13 o más → Agresivo.
4. **Regla de seguridad:** sin fondo de emergencia nunca Agresivo (pasa a Moderado). Afecta al 7,2% de las filas.

5. Supuestos y limitaciones

- Las distribuciones, los puntajes y los cortes son **supuestos del equipo**: no salen de una encuesta ni de un estudio. Deben recalibrarse con datos reales (con consentimiento) antes de producción.
- El modelo aprende a imitar una regla definida por el equipo. Una exactitud alta mide **qué tan bien reproduce el criterio de idoneidad**, no si la recomendación es buena para el usuario.
- La clase Agresivo es minoritaria (10%), así que su F1 es la métrica más frágil.
- `edad` e `ingreso` son variables de idoneidad habituales, pero pueden introducir sesgo. Por eso se miden métricas por grupo (ver la ficha del modelo).

6. Cómo regenerarlo

```
python ia/generar_dataset.py            # 5.000 filas, semilla 42
python ia/generar_dataset.py --n 10000  # otro tamaño
```